



Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

Administración Integral de Riesgo

Examen 2:

Modelo de originación y cobranza

Gustavo Rojas López
Milton Escobar Trujillo
Alexis Gimar Isidro Meza
Ulises Galicia Flores
Roberto López Cancino

Fecha de entrega: 27/05/26

Índice general

1. Introducción	2
2. Preliminares	3
3. Cálculo de reservas	5
3.1. Marco Regulatorio	5
3.2. Preparación de los datos	6
3.3. Evaluación de la Cartera Comercial (Anexo 21)	7
3.3.1. Estratificación y Asignación de Puntajes	7
3.3.2. Modelación de la Probabilidad de Incumplimiento y Estimación de Reservas	8
3.4. Evaluación de Grandes Corporativos (Anexo 22)	8
3.4.1. Criterios y Supuestos Metodológicos de Modelación	8
3.4.2. Modelación de la Probabilidad de Incumplimiento y Estimación de Reservas	9
4. Modelo de originación	10
4.1. Modelo preliminar en Excel	10
4.1.1. Binning y transformación a Weight of Evidence	10
4.1.2. Information Value y selección de variables	10
4.1.3. Estimación por máxima verosimilitud con Solver	11
4.1.4. ScoreCard y política de originación	12
4.2. Implementación mediante Regresión Logística en Python	13
4.2.1. Balance de clases	14
4.2.2. Binning y Weigh of Evidence	15
4.2.3. Information Value	19
4.2.4. Regresión logística	19
4.2.5. ScoreCard	20
4.3. Comparación de modelos, e interpretaciones	24
4.4. Modelo final para la originación	28
5. Modelo de cobranza	30
5.1. Construcción de la variable objetivo	30
5.2. Configuración y preparación de los datos	31
5.3. Balanceo de clases	32
5.4. Entrenamiento del Random Forest multiclase y validación cruzada	32
5.5. Evaluación del modelo (Test / OOT)	33
5.6. Importancia de variables	33
5.7. Semáforo de riesgo y política de cobranza	35
6. Conclusiones	36

Introducción

Dentro del marco de la modelación del riesgo financiero, un modelo de originación es una herramienta analítica y estratégica diseñada para evaluar el perfil y riesgo de los solicitantes de crédito antes de la colocación de un producto financiero. El propósito de este es apoyar a la toma de decisiones mediante el análisis de variables demográficas, financieras, conductuales y de capacidad de pago, permitiendo estimar la probabilidad de las obligaciones adquiridas. De esta manera, el modelo contribuye a una asignación más eficiente del crédito, equilibrando el crecimiento comercial con una adecuada gestión del riesgo.

Dentro de este proceso, el ScoreCard funciona como un mecanismo de calificación que transforma la clasificación y segmentación de los solicitantes según su nivel de riesgo. La utilidad principal de este radica en proporcionar un criterio objetivo, consistente y fácilmente interpretable para la aprobación, rechazo o asignación de condiciones crediticias, es decir, esta herramienta está orientada a traducir los resultados estadísticos en una escala de puntuación que facilite la implementación y capacidad operativa dentro del modelo de originación para su posterior proceso integral de evaluación y toma de decisiones de colocación de crédito.

Desde la perspectiva de regulación, el modelo de originación se desarrollará bajo el marco de *International Financial Reporting Standard 9 (IFRS9)*. El planteamiento y calidad de la originación influye directamente en la estimación de pérdidas crediticias esperadas (*Expected Credit Loss, ECL*), una adecuada identificación y segmentación del riesgo servirá para la correcta estimación de la Probabilidad de Incumplimiento (PD), y por tanto, de las provisiones financieras asociadas a la cartera.

Por otra parte, dentro del mismo contexto de la gestión del riesgo, un modelo de cobranza es una metodología analítica orientada a gestionar y optimizar la recuperación de créditos otorgados, mediante la identificación y segmentación de clientes según su comportamiento de pago y probabilidad de incumplimiento. Su finalidad es establecer estrategias diferenciadas de seguimiento y recuperación, permitiendo priorizar acciones, reducir niveles de morosidad y mejorar la eficiencia operativa, contribuyendo así a preservar la calidad de la cartera y estabilidad financiera de la institución. Este modelo, a diferencia del de originación, se centra en administrar y mitigar el riesgo una vez que el crédito ya ha sido otorgado, definiendo acciones específicas según el nivel de atraso, el perfil del cliente y la capacidad esperada de recuperación.

Preliminares

La base de datos de la cartera a analizar se desarrolla en el archivo `base_tarjetas_credito_060526.xlsx`, donde se encuentran variables como `id_cliente`, `edad`, `sexo`, `nivel_educativo`, `score_buro`, `linea_credito`, `saldo_insoluto`, `porcentaje_uso`, `dias_atraso`, entre otras. Un análisis exploratorio y descriptivo se da a continuación:

Cuadro 2.1: Estadísticos descriptivos y distribuciones de variables

Variable	Count	Mean	Std	Min	25 %	50 %	75 %	Max	Asimetría	Curtosis
Edad	17500	40.23	11.70	18.00	32.00	40.00	48.00	75.00	0.18	-0.31
Score Buró	17500	679.58	78.59	350.00	626.00	680.00	734.00	850.00	-0.08	-0.22
Línea Crédito	17500	218100.98	169897.64	10091.00	105950.75	171717.00	277751.25	1927749.00	2.45	10.42
Saldo Insoluto	17500	103469.30	105418.82	1078.00	35237.75	71594.00	133731.00	1422007.00	2.80	13.60
Porcentaje Uso	17500	47.44	24.64	5.01	25.80	47.58	68.75	90.00	-0.00	-1.21
Días Atraso	17500	21.14	22.45	0.00	0.00	15.00	36.00	131.00	1.00	0.39

Sexo	Frecuencia	%
M	8779	50.17
F	8721	49.83

(a) Distribución por sexo

Nivel educativo	Frecuencia	%
Posgrado	3535	20.20
Primaria	3517	20.10
Preparatoria	3510	20.06
Licenciatura	3502	20.01
Secundaria	3436	19.63

(b) Distribución por nivel educativo




Figura 2.1: Distribución de variables asociadas al perfil del cliente.




Figura 2.2: Distribución de variables relacionadas con la exposición crediticia




Figura 2.3: Distribución de variables de comportamiento y riesgo.

Como se observa en la Figura 2.1, la edad presenta una distribución aproximadamente simétrica. La Figura 2.2 muestra una marcada asimetría positiva en las variables de exposición. Asimismo, la Figura 2.3 evidencia una concentración importante de observaciones en bajos niveles de atraso.

Para la implementación de los modelos, se ocuparán modelos de aprendizaje supervisado, como el modelo de Regresión Logística para originación y Random Forest para el caso de cobranza, éstas metodologías fueron elegidas debido a su interpretabilidad en el contexto que se desarrolla la modelación del riesgo y están basados en la teoría previa en [1] aplicado en Python.

Cálculo de reservas

3.1. Marco Regulatorio

En la presente sección se documenta el desarrollo e implementación metodológica para la evaluación del riesgo de crédito y la consecuente constitución de reservas de una cartera crediticia comercial. Este procedimiento se realiza en estricto apego a las Disposiciones de Carácter General Aplicables a las Instituciones de Crédito emitidas por la Comisión Nacional Bancaria y de Valores (CNBV), bajo el enfoque de pérdida esperada.

El objetivo fundamental de la gestión del riesgo crediticio bajo este marco normativo consiste en cuantificar las pérdidas potenciales en que podría incurrir la institución financiera debido al incumplimiento de sus contrapartes. De este modo, el cálculo de las estimaciones preventivas para riesgos de crédito se fundamenta en la determinación de tres componentes estocásticos y paramétricos esenciales: la Probabilidad de Incumplimiento (PI), la Severidad de la Pérdida (SP) y la Exposición al Incumplimiento (EAD).

La pérdida esperada para cada crédito individual se determina formalmente mediante la siguiente expresión matemática:

$$PE_i = PI_i \times SP_i \times EAD_i$$

Donde:

- PE_i : Representa la Pérdida Esperada del i -ésimo crédito, expresada en términos monetarios, la cual define el monto de la reserva preventiva que debe constituirse.
- PI_i : Es la Probabilidad de Incumplimiento del acreditado, la cual mide la viabilidad de que la contraparte incurra en un evento de default dentro de un horizonte temporal de doce meses. Su obtención depende directamente del modelo de puntuación (scorecard) o asignación de puntaje correspondiente a la naturaleza del cliente.
- SP_i : Denota la Severidad de la Pérdida, definida como la proporción de la exposición que la institución estima que no será posible recuperar una vez ocurrido el incumplimiento, neto de los costos de cobranza y ejecución de garantías. Este parámetro se encuentra regulado por la CNBV, asignando porcentajes fijos según las características y prelación del crédito.
- EAD_i : Es la Exposición al Incumplimiento, que cuantifica el saldo total expuesto al riesgo al momento del evento de default. Para los fines operativos de este desarrollo, corresponde analíticamente al *Saldo Insoluto* vigente registrado en los sistemas de información de la institución.

La normativa de la CNBV establece que las metodologías de calificación deben discriminar a los acreditados comerciales en función de su escala operativa y su nivel de ingresos anuales. En consecuencia, la base de datos disponible para este estudio ha sido segmentada de manera binaria en dos grandes universos regulatorios independientes:

1. **Micro, Pequeñas y Medianas Empresas (MIPYMES)**: Clientes evaluados bajo los lineamientos del Anexo 21, correspondientes a personas morales o personas físicas con

actividad empresarial cuyos ingresos netos o ventas netas anuales se sitúan por debajo del umbral regulatorio equivalente a los 14 millones de Unidades de Inversión (UDIs).

2. **Grandes Corporativos:** Clientes evaluados bajo el esquema del Anexo 22, el cual comprende a las empresas con ingresos o ventas netas anuales iguales o superiores al equivalente de los 14 millones de UDIs, requiriendo un análisis robusto que pondera tanto indicadores cualitativos como financieros.

Previo a la aplicación de los modelos de credit scoring y a la determinación de las curvas de calibración para la *PI*, la regulación exige clasificar a cada acreditado dentro de su sector económico preponderante, definido como aquel de donde provienen la mayor parte de sus ingresos. Para operativizar esta clasificación, se tomaron como base las claves del Sistema de Clasificación Industrial de América del Norte (SCIAN) provistas por el INEGI.

Una vez segmentados los clientes, se procedió al cálculo del puntaje crediticio correspondiente. De acuerdo con la normativa vigente, la integración analítica de los factores de riesgo se estructura mediante una combinación lineal ponderada de componentes cuantitativos (financieros y de comportamiento) y cualitativos:

$$Puntaje\ Total_i = \alpha(Puntaje\ Cuantitativo_i) + (1 - \alpha)(Puntaje\ Cualitativo_i)$$

Donde $\alpha \in [0, 1]$ representa el peso específico asignado por la autoridad a cada bloque de riesgo (por ejemplo, $\alpha = 0.85$ para el esquema de Grandes Corporativos del Anexo 22). El *Puntaje Cuantitativo* se obtiene a través del mapeo paramétrico de razones financieras y métricas de historial de pago, mientras que el *Puntaje Cualitativo* se determina con base en variables institucionales y características no numéricas del entorno corporativo del cliente.

Finalmente, el puntaje crediticio total consolidado es transformado a una escala probabilística continua. Para ello, las Disposiciones Generales dictan el empleo de una función logística de calibración (sigmoide), parametrizada bajo el supuesto de que un puntaje de referencia define las condiciones de doble simetría en el riesgo:

$$PI_i = \frac{1}{1 + e^{-(500 \times Puntaje\ Crediticio\ Total_i) \times \frac{\ln(2)}{40}}}$$

La obtención de esta probabilidad, en conjunción con los parámetros fijos de severidad y los saldos de exposición vigentes, provee la infraestructura analítica completa para cuantificar la Pérdida Esperada y modelar los requerimientos de reservas de capital de la institución.

3.2. Preparación de los datos

Con el objeto de sistematizar la clasificación de los acreditados según su sector económico preponderante y garantizar la consistencia en las fases subsecuentes de cálculo, se diseñó e implementó un algoritmo de mapeo matricial en el lenguaje de programación Python. A través de la construcción de un diccionario de estructuras indexadas, las claves del Sistema de Clasificación Industrial de América del Norte (SCIAN) provistas en la base general fueron homogeneizadas y canalizadas hacia los cinco sectores económicos fundamentales regulados por la autoridad supervisora: i) Agrícola, ii) Explotación, Energía y Construcción, iii) Manufactura, iv) Comercio, y v) Servicios.

La codificación de este proceso de reestructuración de variables se detalla en el siguiente fragmento de código:

```

1 # Diccionarios de sectores economicos
2 grupos_scian = {
3     'Agricola': [11],
4     'Explotacion, Energia y Construccion': [21, 22, 23],
5     'Manufactura': [31, 32, 33],
6     'Comercio': [43, 46],
7     'Servicios': [48, 49, 51, 52, 53, 54, 55, 56, 61, 62, 71, 72, 81, 93]
8 }
9
10 diccionario_sectores = {}
11 for sector, claves in grupos_scian.items():
12     for clave in claves:
13         diccionario_sectores[clave] = sector
14
15 df_anexo_21['Sector'] =
16     df_anexo_21['scian'].map(diccionario_sectores).fillna('Explotacion, Energia y
17     Construccion')

```

Es importante destacar que la función `.fillna()` opera como un mecanismo prudencial de control; ante cualquier omisión o inconsistencia en el registro original de la clave SCIAN, el algoritmo asigna por defecto el sector de *Explotación, Energía y Construcción*, alineándose estrictamente con las disposiciones normativas de la CNBV.

3.3. Evaluación de la Cartera Comercial (Anexo 21)

Bajo los lineamientos establecidos en el Anexo 21, la cuantificación del riesgo de crédito para el portafolio de MIPYMES se instrumenta de manera exclusiva mediante un enfoque paramétrico cuantitativo ($\alpha = 1.0$). Por consiguiente, el modelo prescinde de factores cualitativos e aísla el riesgo evaluando de forma directa la dinámica de comportamiento de pago y la experiencia crediticia del acreditado, tanto en el seno de la propia institución como ante el resto de las entidades del sistema financiero.

3.3.1. Estratificación y Asignación de Puntajes

La asignación de la puntuación crediticia individual se ejecuta mediante la evaluación de estructuras condicionales que analizan los porcentajes de pagos en tiempo y el historial de días de mora, parametrizados de forma diferenciada de acuerdo con las matrices de riesgo correspondientes a cada sector económico. A modo de ilustración, a continuación se presenta la codificación algorítmica diseñada para procesar el comportamiento de pago en entidades bancarias:

```

1 # Asignacion de puntos por pagos en tiempo con entidades bancarias
2 def puntos_pagos_bancarios(row):
3     sector = row['Sector']
4     pct = row['Porcentaje_Pagos_Tiempo_Bancarias']
5
6     if sector in ['Agricola']:
7         if pct > 99: return 168
8         elif pct > 95: return 142
9         elif pct >= 0: return 65
10        else: return 133
11    # (...) El algoritmo replica analiticamente las matrices correspondientes a los
12    sectores restantes.

```

```

12 df_anexo_21['Puntos_Pago_Bancario'] = df_anexo_21.apply(puntos_pagos_bancarios,
13 axis=1)
14 df_anexo_21[['id_cliente', 'Sector', 'Puntos_Pago_Bancario']]

```

3.3.2. Modelación de la Probabilidad de Incumplimiento y Estimación de Reservas

Una vez consolidada la agregación lineal de las subpuntuaciones cuantitativas para determinar el *Puntaje Crediticio Total* de cada acreditado, este valor se transforma en un indicador de probabilidad continua empleando la función de calibración logística estipulada en el cuerpo metodológico de las Disposiciones de la CNBV.

Por otra parte, respecto al parámetro de Severidad de la Pérdida (SP_i), la regulación prescribe que, al tratarse de posiciones crediticias comerciales desgarantizadas (cartera sin colaterales elegibles o coberturas reales de riesgo), se debe adoptar de manera estática un coeficiente de pérdida del 55.0 %.

A partir de la conjunción analítica de estos componentes estocásticos y el Saldo Insoluto como medida de la Exposición al Incumplimiento (EAD_i), se derivó el requerimiento de provisiones de capital. Los resultados econométricos y monetarios finales para los clientes muestra evaluados en este bloque se exponen en la Tabla 3.1.

ID Cliente	Sector	Puntaje	PI (%)	SP (%)	EAD (\$)	Reserva (\$)
4225	Comercio	382.0	88.54 %	55.0 %	48,211.00	23,477.83
15385	Explotación	413.0	81.87 %	55.0 %	80,741.00	36,356.66

Cuadro 3.1: Resultados del perfil de riesgo y constitución de estimaciones preventivas (Anexo 21).

3.4. Evaluación de Grandes Corporativos (Anexo 22)

A diferencia del esquema simplificado aplicado al portafolio de MIPYMES, la metodología analítica del Anexo 22 instrumenta un proceso de calificación multidimensional para empresas de gran escala operativa (≥ 14 millones de UDIs). Este modelo integra de manera simultánea indicadores de solvencia financiera (dimensión cuantitativa) con variables relativas a la estructura organizacional y de control corporativo (dimensión cualitativa).

3.4.1. Criterios y Supuestos Metodológicos de Modelación

Con el propósito de aplicar los algoritmos analíticos dictados por las disposiciones de la CNBV frente a las restricciones inherentes a la estructura de la base de datos origen, se adoptaron los siguientes criterios metodológicos y prudenciales:

- **Homologación de Ingresos Operativos:** Ante la ausencia de un campo explícito que cuantificara los Ingresos Totales agregados en el sistema de origen, se seleccionó el rubro de *Ventas Netas* como la variable *proxy* analítica para el cómputo de las razones de actividad y eficiencia operativa, tales como la rotación de activos fijos y el costo de financiamiento sobre ventas.
- **Ajuste Conservador de Liquidez:** Para la determinación de la Razón de Efectivo, y con el fin de evitar una sobreestimación artificial de la capacidad de pago inmediata de las contrapartes, la partida de *Inversiones a Corto Plazo* se aproximó a cero (0.0). Con ello,

la métrica de liquidez se restringe estrictamente a la disponibilidad inmediata en caja y equivalentes de efectivo bancarios.

- **Criterio de Elegibilidad por Escala:** Se asume de manera exógena que el universo de clientes asignado a este bloque cumple rigurosamente con los umbrales de facturación anual requeridos por la normativa para ser catalogados como *Grandes Corporativos*, validando la aplicación del vector de ponderación del 85 % sobre el componente financiero.
- **Imputación de Brechas de Información Cualitativa:** Debido a que los registros transaccionales de la base de datos omiten variables relativas a las estructuras internas de gobierno corporativo, se recurrió a la salvaguarda prudencial prevista en la propia regulación. Se asignó homogéneamente la categoría de «Sin Información» a los vectores correspondientes, lo que otorga el puntaje base estandarizado establecido por la autoridad supervisora (por ejemplo, 121 puntos en el indicador de Estabilidad Económica).

3.4.2. Modelación de la Probabilidad de Incumplimiento y Estimación de Reservas

Respecto al parámetro de Severidad de la Pérdida (SP_i), las disposiciones de la CNBV estipulan una tasa fija del 45.0 % para exposiciones comerciales con Grandes Corporativos que carecen de colaterales elegibles o garantías reales mitigantes de riesgo. Esta tasa refleja una expectativa de recuperación regulatoria marginalmente superior a la del portafolio de menor escala.

Tras evaluar y transformar el espectro de razones financieras obligatorias, se procedió a consolidar el *Puntaje Total* mediante la siguiente combinación lineal ponderada:

$$Puntaje\ Total_i = 0.85(Puntaje\ Cuantitativo_i) + 0.15(Puntaje\ Cualitativo_i)$$

Posterior al cálculo de la Probabilidad de Incumplimiento correspondiente, se determinaron con exactitud los requerimientos monetarios de capital preventivo necesarios para mitigar la pérdida esperada de este segmento de la cartera. Los resultados analíticos obtenidos para los corporativos de muestra se detallan en la Tabla 3.2.

ID Cliente	Sector	Puntaje	PI (%)	SP (%)	EAD (\$)	Reserva (\$)
7950	Explotación	610.60	12.82 %	45.0 %	26,451.00	1,526.51
9403	Comercio	457.60	67.58 %	45.0 %	22,236.00	6800.95
15883	Explotación	525.60	39.09 %	45.0 %	7,400.00	1,301.63

Cuadro 3.2: Resultados del perfil de riesgo y constitución de estimaciones preventivas (Anexo 22).

Modelo de originación

4.1. Modelo preliminar en Excel

Previo a la implementación en Python, se construyó un modelo preliminar íntegramente en una hoja de cálculo, con el objeto de reproducir de forma transparente y auditable cada etapa del *scorecard*, la discretización de las variables (*binning*), su transformación a *Weight of Evidence* (WoE), la medición de su poder predictivo mediante el *Information Value* (IV), la estimación de la regresión logística por máxima verosimilitud y, finalmente, la definición de la política de originación. A diferencia del enfoque en Python, este modelo se ajusta directamente sobre la totalidad de la cartera ($n = 17\,500$), sin técnicas de balanceo de clases, empleando como variable objetivo el mismo criterio de Basilea II,

$$\text{Target} = \text{Si}(\text{dias_atraso}, 1, 0)$$

que arroja 104 eventos de mora, equivalentes a una tasa de morosidad del 0.594 %.

4.1.1. Binning y transformación a Weight of Evidence

La discretización de las variables numéricas se realizó por tramos de igual frecuencia, tomando como puntos de corte los percentiles 20, 40, 60 y 80 calculados sobre la cartera mediante PERCENTILE.INC, lo que genera cinco tramos por variable. A modo de ilustración se detalla el procedimiento para la variable edad, el resto de variables numéricas se procesa de manera análoga, mientras que para las variables categóricas (*sexo*, *estado_civil*, *nivel_educativo*) cada categoría constituye por sí misma un tramo, prescindiendo del corte por percentiles.

Para edad, los percentiles obtenidos fueron 30, 37, 43 y 50 años. La asignación del tramo a cada acreditado se efectúa mediante una estructura condicional anidada,

$$=\text{IF}(\text{edad} \leq \$U\$2, 1, \text{IF}(\text{edad} \leq \$U\$3, 2, \text{IF}(\text{edad} \leq \$U\$4, 3, \text{IF}(\text{edad} \leq \$U\$5, 4, 5))))$$

donde \$U\$2 : \$U\$5 contienen los percentiles de corte. Una vez clasificada cada observación, se contabilizan los clientes buenos (Target = 0) y malos (Target = 1) por tramo mediante COUNTIFS y se obtienen sus proporciones relativas respecto al total de buenos y de malos. El WoE de cada tramo se define como

$$\text{WoE}_i = \ln\left(\frac{\% \text{Buenos}_i}{\% \text{Malos}_i}\right),$$

de modo que un valor positivo identifica tramos de menor riesgo relativo y uno negativo, tramos con mayor concentración de mora. Los resultados para edad se presentan en el Cuadro 4.1.

4.1.2. Information Value y selección de variables

El poder discriminante de cada variable se cuantifica agregando la contribución de todos sus tramos a través del *Information Value*,

$$\text{IV} = \sum_i (\% \text{Buenos}_i - \% \text{Malos}_i) \text{WoE}_i.$$

Cuadro 4.1: Binning, WoE e IV de la variable edad (modelo en Excel).

Tramo	Rango (años)	Buenos	Malos	% Buenos	% Malos	WoE	IV
1	≤ 30	3690	20	0.2123	0.1739	0.1992	0.0076
2	(30, 37]	3562	21	0.2049	0.1826	0.1151	0.0026
3	(37, 43]	3436	20	0.1976	0.1739	0.1279	0.0030
4	(43, 50]	3357	30	0.1931	0.2609	-0.3008	0.0204
5	> 50	3340	24	0.1921	0.2087	-0.0828	0.0014
Total		17385	115				0.0350

Para edad, la suma de la última columna del Cuadro 4.1 arroja $IV = 0.0350$. Replicando el cálculo para las nueve variables candidatas y ordenando de mayor a menor capacidad predictiva se obtiene el Cuadro 4.2. Siguiendo la convención de Siddiqi, que fija $IV > 0.02$ como umbral mínimo de poder discriminante, se descartan *nivel_educativo* ($IV = 0.0152$) y *sexo* ($IV = 0.0022$); esta última, adicionalmente, por tratarse de un atributo protegido cuya inclusión resulta improcedente en un modelo de otorgamiento. Las variables *linea_credito* y *saldo_Insoluto*, pese a situarse marginalmente por debajo del umbral, se conservan por continuidad con el núcleo cuantitativo del modelo y porque la fuerte asimetría positiva de estas exposiciones (coeficientes de asimetría de 2.45 y 2.80, véase el Cuadro 2.1) provoca que el *binning* por percentiles fijos subestime su IV; la discretización óptima de la Sección 4.2.2 recupera posteriormente dicho poder. El conjunto finalmente seleccionado coincide con el del modelo en Python, siete predictores, incorporando *estado_civil* como única variable categórica.

Cuadro 4.2: Information Value por variable y decisión de selección (modelo en Excel).

Variable	Tipo	Tramos	IV	Poder predictivo	Seleccionada
<i>estado_civil</i>	Categórica	4	0.0524	Débil	Sí
<i>porcentaje_uso</i>	Numérica	5	0.0484	Débil	Sí
<i>score_buro</i>	Numérica	5	0.0473	Débil	Sí
<i>ingreso_mensual</i>	Numérica	5	0.0381	Débil	Sí
<i>edad</i>	Numérica	5	0.0350	Débil	Sí
<i>saldo_Insoluto</i>	Numérica	5	0.0174	Sin poder pred.	Sí*
<i>nivel_educativo</i>	Categórica	5	0.0152	Sin poder pred.	No
<i>linea_credito</i>	Numérica	5	0.0054	Sin poder pred.	Sí*
<i>sexo</i>	Categórica	2	0.0022	Sin poder pred.	No

* Retenidas por continuidad con el modelo base; su IV se recupera bajo el *binning* óptimo de la Sección 4.2.2.

4.1.3. Estimación por máxima verosimilitud con Solver

Con las variables seleccionadas transformadas a WoE —una columna por predictor, obtenida con VL00KUP sobre las tablas de WoE por tramo—, el modelo logístico se expresa como

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{k=1}^7 \beta_k \text{WoE}_k =: Z, \quad p = \frac{1}{1 + e^{-Z}},$$

con $p = P(\text{Target} = 1 \mid x)$. A diferencia de la regresión lineal, los coeficientes de la regresión logística carecen de solución analítica cerrada, por lo que se estimaron numéricamente por máxima verosimilitud. Para ello se dispusieron los coeficientes $\beta_0, \dots, \beta_7$ en celdas auxiliares (inicializadas en cero); para cada una de las 17 500 observaciones se calcula su predictor lineal Z , su probabilidad p y su aportación a la función de pérdida logística (entropía cruzada binaria),

$$\mathcal{L}(\beta) = - \sum_{i=1}^n \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right].$$

La celda que acumula $\mathcal{L}(\beta)$ se fija como objetivo en el complemento *Solver*, configurado para minimizarla mediante el método GRG No Lineal, variando exclusivamente las celdas de coeficientes. Dado que minimizar la log-verosimilitud negativa equivale a maximizar la verosimilitud, al converger el algoritmo las celdas auxiliares contienen los estimadores de máxima verosimilitud. Los coeficientes obtenidos se reportan en el Cuadro 4.3; su signo negativo es coherente con la escala WoE (a mayor WoE, menor riesgo) y su magnitud cercana a la unidad refleja la estandarización implícita que introduce dicha transformación.

Cuadro 4.3: Coeficientes de la regresión logística estimados con Solver (modelo en Excel).

Término	Coficiente
Intercepto (β_0)	-5.0182
edad	-1.0120
ingreso_mensual	-0.9864
score_buro	-1.0139
linea_credito	-1.0298
porcentaje_uso	-0.9505
saldo_Insoluto	-0.9511
estado_civil	-1.0307

4.1.4. ScoreCard y política de originación

Para traducir la salida del modelo a una escala interpretable se aplicó la misma calibración de la Sección 4.2.4 (en donde se desarrolla más a fondo este procedimiento), con $PDO = 20$, $Score_{base} = 600$ y $Odds_{base} = 50$ se obtienen $Factor = PDO/\ln 2 = 28.85$ y $Offset = Score_{base} - Factor \cdot \ln(Odds_{base}) = 487.12$. Definiendo $Odds = (1 - p)/p$, el puntaje de cada solicitante es

$$Score = Offset + Factor \cdot \ln(Odds) = Offset - Factor \cdot Z,$$

expresión equivalente a la suma de las aportaciones en puntos de cada tramo. Sobre la cartera, los puntajes resultantes se distribuyen entre 587 y 680 puntos.

A partir de la distribución empírica de la tasa de mora por banda de puntaje se definió una política de tres zonas, gobernada por dos umbrales parametrizables: se **aprueba** de forma automática a quien obtiene $Score \geq 640$ (tasa de mora observada del 0.32 %, ≈ 38 % de la cartera); se **refiere** a evaluación manual el tramo $620 \leq Score < 640$ (0.68 %, ≈ 48 %); y se **rechaza** a quien queda por debajo de 620 puntos (1.53 % de mora en la banda inmediata inferior, más del doble del promedio de la cartera). El Cuadro 4.4 muestra la aplicación íntegra del algoritmo —de los insumos crudos al puntaje y a la decisión final— sobre cinco solicitantes reales de la base.

Cuadro 4.4: Aplicación del *scorecard* a cinco solicitantes (modelo en Excel).

Id	Edad	Ingreso	Score buró	Línea	% Uso	Saldo	Edo. civil	Z	p	Puntaje	Decisión
10	34	10 682	681	55 170	53.45	29 486	Viudo	-6.211	0.0020	666.3	Aprobar
2	27	40 152	643	103 968	20.14	20 941	Soltero	-5.441	0.0043	644.1	Aprobar
7	31	45 504	690	191 294	24.68	47 220	Divorciado	-4.954	0.0070	630.1	Referir
134	38	91 229	627	186 831	21.92	40 953	Divorciado	-4.314	0.0132	611.6	Rechazar
39	47	79 010	813	592 208	89.31	528 895	Divorciado	-3.882	0.0202	599.1	Rechazar

Este modelo preliminar constituye la línea base transparente sobre la que se construye la implementación en Python de la Sección 4.2, en la que el *binning* óptimo y las estrategias de balanceo de clases refinan tanto la separación de riesgo como la estabilidad fuera de muestra del modelo.

4.2. Implementación mediante Regresión Logística en Python

Antes del modelo de regresión, es importante destacar el procedimiento previo que hacen válida la inferencia de la metodología de aprendizaje supervisado, dentro de lo que primeramente destaca la distribución observada de la variable objetivo **dias_atraso** y su posterior tratamiento, en este parte, basándose en *Basilea II* [3], se tomó como referencia para morosidad:

$$\text{Default} = \text{dias_atraso} > 90$$

esta variable dependiente se renombró como Target.

Cuadro 4.5: Distribución de la variable objetivo (Target)

Clase	Frecuencia	Porcentaje
0 (Al corriente)	17396	99.406
1 (Moroso)	104	0.594

Métrica	Valor
Dimensiones de la base	(17500, 25)
Tasa de morosidad	0.594 %

Cuadro 4.6: Variables candidatas para el modelo de originación

Tipo	Variables
Numéricas	edad, ingreso_mensual, score_buro, linea_credito, porcentaje_uso, saldo_Insoluto
Categorías	sexo, estado_civil, nivel_educativo

Antes de estimar el *Information Value* para discriminar a las variables candidatas, se necesita hacer énfasis en la separación de los datos de entrenamiento, prueba y OOT (*Out of Time*), esta consiste en evaluar el algoritmo en un periodo posterior al que se utilizó en el entrenamiento del modelo, que es de ayuda para comprobar si el modelo sigue siendo preciso ante nueva información y paso del tiempo.

Sin embargo, ante la falta de una variable temporal de referencia para distinguir la prueba OOT del conjunto de entrenamiento se optó por partir aleatoriamente el conjunto general de datos, que se especifican en la siguiente tabla:

Cuadro 4.7: Partición de la muestra y distribución de eventos

Conjunto	Observaciones	Morosos
Train (60 %)	10500	63
Test (20 %)	3500	20
Out-of-Time (20 %)	3500	21
Total	17500	104

La distribución de eventos morosos se mantuvo relativamente homogénea entre los conjuntos, con 63 observaciones en entrenamiento, 20 en prueba y 21 en validación, preservando la representatividad de la variable objetivo para el proceso de modelado y evaluación.

4.2.1. Balance de clases

Ahora antes de entrar al entrenamiento del modelo de aprendizaje supervisado, cabe destacar la distribución del Target (días_atraso) que se mostró gráficamente en la sección preliminar, esto es importante trabajarlo porque hay un sesgo en la frecuencia de clientes al corriente (Target = 1) y morosos (Target = 0), por lo que basándose directamente en esta información, la Regresión logística entrenada tendría que aprender a predecir directamente clientes al corriente, obteniendo una precisión aparentemente muy alta para esta clase, pero sería inútil para detectar clientes en mora. Para esto se tiene que emplear técnicas de submuestreo o sobremuestreo (Oversampling, Undersampling) para ayudar a equilibrar las clases de la variable dependiente.

Matemáticamente, el *oversampling* mediante el método de SMOTE genera nuevas observaciones sintéticas para la clase minoritaria (Target_i = 1), interpolando entre un punto y sus vecinos más cercanos. Es decir, dada una observación minoritaria $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})$ y uno de sus k vecinos más cercanos $x_j = (x_{j1}, x_{j2}, \dots, x_{jp})$, donde las componentes son las observaciones puntuales de las variables predictoras, se genera una nueva observación sintética:

$$x_{\text{nuevo}} = x_i + \lambda(x_j - x_i), \quad \lambda \sim U(0, 1)$$

donde si $\lambda = 0$, el nuevo punto coincide con x_i , si $\lambda = 1$ coincide con x_j y si $0 < \lambda < 1$, el nuevo punto queda entre ambos. Por ejemplo, Sea una observación perteneciente a la clase minoritaria:

$$x_i = (10000, 650, 42, 250000, 0.65)$$

que representa: (Ingreso, Score, Edad, Línea de crédito, Porcentaje de uso). Supóngase un vecino cercano de la misma clase:

$$x_j = (15000, 700, 45, 300000, 0.75)$$

y un valor $\lambda = 0.4$, entonces, SMOTE genera una nueva observación sintética mediante:

$$x_{\text{nuevo}} = x_i + \lambda(x_j - x_i)$$

Sustituyendo:

$$\begin{aligned} x_{\text{nuevo}} &= (10000, 650, 42, 250000, 0.65) \\ &\quad + 0.4 \left[(15000, 700, 45, 300000, 0.75) - (10000, 650, 42, 250000, 0.65) \right] \\ &= (10000, 650, 42, 250000, 0.65) + 0.4(5000, 50, 3, 50000, 0.10) \\ &= (10000, 650, 42, 250000, 0.65) + (2000, 20, 1.2, 20000, 0.04) \\ &= (12000, 670, 43.2, 270000, 0.69) \end{aligned}$$

Por lo tanto, la nueva observación sintética corresponde a un cliente con ingreso mensual de 12 000, score de buró de 670, edad de 43.2 años, línea de crédito de 270 000 y porcentaje de uso de 69 %.

El *undersampling* funciona de manera opuesta a SMOTE, es decir, en lugar de crear nuevas observaciones de la clase minoritaria, elimina observaciones de la clase mayoritaria hasta reducir el desbalance. Por otra parte, si el balance se hiciera por percentiles, aunque esto es menos agresivo que el submuestreo, requeriría incrementar considerablemente la clase minoritaria o reducir excesivamente la mayoritaria, alterando la estructura real de la población y pudiendo

generar estimaciones sesgadas de la probabilidad de incumplimiento, esto hace a ambas técnicas no tan apropiadas para el tratamiento de balanceo de clases en esta cartera.

Por otra parte, el método *Class Weight* no modifica la estructura de la base de datos ni genera nuevas observaciones sintéticas. En su lugar, asigna pesos diferenciados a cada clase durante el proceso de optimización del modelo, incrementando la penalización asociada a errores sobre la clase minoritaria ($Target_i = 1$). De esta forma, la regresión logística otorga una mayor importancia relativa a los eventos poco frecuentes durante el aprendizaje.

Para una base de datos con N observaciones totales, k clases y N_j observaciones pertenecientes a la clase j , el peso asignado a cada clase se calcula como:

$$w_j = \frac{N}{kN_j}$$

En el caso de una regresión logística convencional, la función de pérdida se expresa como:

$$L = - \sum_{i=1}^n \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right]$$

donde: $p_i = P(Y_i = 1|X_i)$

Al introducir ponderaciones por clase, la función objetivo se transforma en:

$$L_w = - \sum_{i=1}^n w_i \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right]$$

De esta manera, las observaciones pertenecientes a la clase minoritaria reciben una mayor penalización cuando son clasificadas incorrectamente, desplazando la frontera de decisión hacia una representación más equilibrada entre eventos y no eventos, sin alterar la distribución original de los datos.

La principal ventaja de este enfoque respecto al sobremuestreo mediante SMOTE es que no genera observaciones artificiales, preservando la interpretación probabilística original del modelo. Asimismo, a diferencia del submuestreo, evita la eliminación de una gran cantidad de observaciones reales, y frente al balanceo por percentiles mantiene intacta la estructura poblacional original. Debido a la presencia de un desbalance severo en la base de datos analizada (0.594 % de morosidad), este método permite mejorar el aprendizaje del modelo sin introducir distorsiones adicionales en la información disponible.

4.2.2. Binning y Weigh of Evidence

La implementación del *binning* desde el enfoque de Python sigue la misma lógica estructural que la sección preliminar de la construcción de esta parte en Excel, en Python se implementó desde la librería **OptBinning** mediante el parámetro `monotonic_trend='auto_asc_desc'` que le indica al algoritmo que detecte automáticamente si la relación óptima entre la variable y el riesgo debe ser creciente o decreciente y selecciona la que mejor ajuste los datos (generalmente maximizando separación/IV bajo restricciones de estabilidad).




Figura 4.1: Monotonía de WOE mediante el balanceo previo por *Oversampling*




Figura 4.2: Monotonía de WOE mediante el balanceo previo por percentiles




Figura 4.3: Monotonía de WOE mediante el balanceo previo por *Class Weight*

La implementación en Python sigue la misma estructura que en Excel, solo que en este software se emplea de manera interna mediante la clase *OptimalBinning*, cuyos resultados se muestran en 4.1, 4.2 y 4.3, donde se observa claramente la monotonía de los WOE's para cada tipo de balance de clases.

La diferencia con el modelo de Excel, es que posterior al calculo de los WoE's se transforman las variables originales de los conjuntos de entrenamiento, prueba y OOT a su representación en WoE utilizando los bins construidos previamente, reemplazando valores como ingreso, edad o score de buró por una medida basada en la evidencia estadística de buenos y malos. De esta forma, cada observación deja de expresarse en su escala original y pasa a representarse mediante un valor asociado a su nivel de riesgo crediticio, permitiendo que la regresión logística trabaje con variables más interpretables, con relaciones más estables y aproximadamente lineales respecto a la probabilidad de incumplimiento.

```

1 # Transformacion a WoE de las 3 particiones
2 Xtr = transformar_woe(bins_orig, train_bal, vars_sel)
3 ytr = train_bal['Target'].values
4 Xte = transformar_woe(bins_orig, test, vars_sel)
5 yte = test['Target'].values
6 Xoo = transformar_woe(bins_orig, oot, vars_sel)
7 yoo = oot['Target'].values
8 woe_features = list(Xtr.columns)
9 Xtr.head()

```

Las siguientes tablas ilustran a lo que se quiere llegar para diferenciar los diferentes datos con los que se va a alimentar el modelo de Regresión logística en cada caso de balance:

Cuadro 4.8: Primeras observaciones del conjunto entrenado con WoE | Oversampling

Ingreso mensual WoE	Score buró WoE	Saldo insoluto WoE	Estado civil WoE	Línea crédito WoE	% uso WoE	Edad WoE
0.122426	-0.079849	0.085081	1.697702	-0.285926	-0.059460	-0.124311
-0.452980	-0.079849	0.085081	-0.286892	-0.285926	-0.059460	-0.124311
0.122426	1.198631	0.085081	-0.101882	-0.285926	-0.059460	-0.124311
0.433882	-0.079849	0.369206	-0.286892	0.811968	0.383866	1.301257
0.122426	0.009635	0.085081	-0.286892	0.098600	-0.059460	0.394225

Cuadro 4.9: Primeras observaciones del conjunto entrenado con WoE | Percentiles

Ingreso mensual WoE	Score buró WoE	Saldo insoluto WoE	Estado civil WoE	Línea crédito WoE	% uso WoE	Edad WoE
-0.027399	-0.788457	0.322773	0.788457	0.303682	0.000000	0.160343
-0.027399	0.143101	0.322773	0.788457	0.303682	0.000000	0.171850
-0.027399	0.143101	-0.693147	-0.441833	-0.653926	-1.791759	-0.344840
0.693147	0.287682	0.322773	-0.271934	0.303682	-0.080043	-0.344840
-0.027399	0.143101	0.322773	-0.441833	0.303682	0.000000	0.171850

Cuadro 4.10: Primeras observaciones del conjunto entrenado con WoE | Class Weight

Ingreso mensual WoE	Score buró WoE	Saldo insoluto WoE	Estado civil WoE	Línea crédito WoE	% uso WoE	Edad WoE
0.119942	0.042613	0.184532	0.483618	-0.290545	-0.252046	0.427919
-0.804225	0.042613	0.069228	-0.162795	-0.473863	-0.252046	-0.069090
0.119942	0.139473	0.184532	0.111150	-0.290545	-0.252046	-0.069090
0.433423	0.042613	0.184532	-0.162795	0.566776	-0.252046	-0.069090
0.433423	0.139473	0.184532	-0.162795	0.159254	-0.252046	-0.069090

4.2.3. Information Value

El proceso de selección de variables predictoras, como se menciona anteriormente, se hace mediante el *Information Value*, cuyo procedimiento interno se hace mediante el procedimiento de la Sección 4.1.2 que se implementó de forma secuencial en Excel, los resultados son los siguientes:

Cuadro 4.11: Information Value (IV) para variables con Oversampling

Variable	Tipo	Tramos	IV	Poder predictivo	Seleccionada
ingreso_mensual	Numérica	4	0.1586	Medio	Sí
score_buro	Numérica	5	0.0895	Débil	Sí
saldo_Insoluto	Numérica	3	0.0882	Débil	Sí
estado_civil	Catégorica	4	0.0807	Débil	Sí
linea_credito	Numérica	5	0.0756	Débil	Sí
porcentaje_uso	Numérica	3	0.0565	Débil	Sí
edad	Numérica	2	0.0295	Débil	Sí
nivel_educativo	Catégorica	5	0.0016	Sin poder predictivo	No
sexo	Catégorica	2	0.0000	Sin poder predictivo	No

Cuadro 4.12: Comparación del análisis IV entre percentiles y *Class Weight*

Modelo Balanceado			Modelo Class Weight		
Variable	Tramos	IV	Variable	Tramos	IV
ingreso_mensual	4	0.3508	ingreso_mensual	4	0.1586
score_buro	4	0.0950	score_buro	5	0.0895
saldo_Insoluto	5	0.1926	saldo_Insoluto	3	0.0882
estado_civil	4	0.2106	estado_civil	4	0.0807
linea_credito	4	0.2910	linea_credito	5	0.0756
porcentaje_uso	4	0.2186	porcentaje_uso	3	0.0565
edad	3	0.0567	edad	2	0.0295

4.2.4. Regresión logística

Ahora, con *Xtr* y *ytr* se tiene el conjunto de entrenamiento preparado para el proceso de modelado, donde *Xtr* contiene las variables predictoras transformadas mediante *WoE* y *ytr* la variable objetivo asociada. A partir de esta información se entrena el modelo de regresión logística mediante la clase `LogisticRegression` de la librería *scikit-learn*.

```
1 logit = LogisticRegression(solver='liblinear', random_state=semilla).fit(Xtr, ytr)
```

Esta implementación es independiente del método de balanceo, más no el resultado, que depende directamente de las transformaciones *WoE* a las variables predictoras.

Para los siguientes 3 resultados dependientes del balance de clases, a lo que se llega es a la estructura:

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{k=1}^7 \beta_k \cdot \text{WoE}_k$$

de donde nos interesa

$$\mathbb{P}(\text{Target} = 1 \mid x) = \frac{1}{1 + e^{-\text{logit}(p)}}$$

Para los diferentes casos de balances se tienen los siguientes resultados:

Cuadro 4.13: Balance por *Oversampling*

Término	Coef.
Intercepto (β_0)	0.0025
ingreso_mensual_woe	-0.5383
score_buro_woe	-0.9602
saldo_Insoluto_woe	-0.4695
estado_civil_woe	-1.0475
linea_credito_woe	-0.4574
porcentaje_uso_woe	-0.7726
edad_woe	-0.9524

Cuadro 4.14: Balance por Percentiles

Término	Coef.
Intercepto (β_0)	-0.0023
ingreso_mensual_woe	-0.4543
score_buro_woe	-0.7788
saldo_Insoluto_woe	0.2641
estado_civil_woe	-0.8298
linea_credito_woe	-0.6072
porcentaje_uso_woe	-0.8058
edad_woe	-0.4789

Cuadro 4.15: Balance por *Class Weight*

Término	Coef.
Intercepto (β_0)	-0.0036
ingreso_mensual_woe	-0.9257
score_buro_woe	-0.8357
saldo_Insoluto_woe	-1.3738
estado_civil_woe	-1.2621
linea_credito_woe	0.7247
porcentaje_uso_woe	-1.7155
edad_woe	-1.2091

4.2.5. ScoreCard

Dado que en la sección anterior se estimó la regresión logística, se define

$$\text{Odds} := \frac{1-p}{p}$$

lo que es equivalente a:

$$\ln(\text{Odds}) = -\ln\left(\frac{p}{1-p}\right)$$

Para la construcción del *ScoreCard* es necesario definir previamente ciertos parámetros de calibración que permitan transformar la salida de la regresión logística a una escala de puntos interpretable. Uno de los parámetros más importantes corresponde al *Points to Double Odds* (PDO), el cual representa la cantidad de puntos adicionales necesarios para duplicar las *odds* o razones de probabilidad asociadas al evento de interés. En términos prácticos, el PDO determina la sensibilidad de la escala del *score*, estableciendo cuánto debe variar la puntuación ante cambios en el riesgo estimado.

Bajo este esquema, el score total se modela como una transformación lineal de las *odds* en escala logarítmica:

$$\text{Score} = \text{Offset} + \text{Factor} \times \ln(\text{Odds})$$

donde *Offset* corresponde a un desplazamiento fijo y *Factor* determina la amplitud o sensibilidad de la escala utilizada.

Debido a la definición del PDO, el sistema debe satisfacer que un incremento de dicha cantidad de puntos implique una duplicación de las *odds*, es decir:

$$\text{Score} + \text{PDO} = \text{Offset} + \text{Factor} \times \ln(2 \times \text{Odds})$$

Por otra parte, a partir de la formulación de la regresión logística se tiene que las *odds* pueden expresarse mediante la función lineal estimada por el modelo:

$$\ln(\text{Odds}) = - \left(\beta_0 + \sum_{k=1}^7 \beta_k x_k \right)$$

donde β_k representan los coeficientes estimados por el modelo, x_k las variables explicativas transformadas mediante WoE y β_0 el intercepto.

Sustituyendo las relaciones anteriores y utilizando la condición establecida por el PDO, se tiene:

$$\text{Score} + \text{PDO} = \text{Offset} + \text{Factor} \times \ln(2 \times \text{Odds})$$

Aplicando la propiedad de los logaritmos:

$$\text{Score} + \text{PDO} = \text{Offset} + \text{Factor} [\ln(2) + \ln(\text{Odds})]$$

Por definición:

$$\text{Score} = \text{Offset} + \text{Factor} \times \ln(\text{Odds})$$

Sustituyendo esta expresión en la igualdad anterior:

$$\text{Offset} + \text{Factor} \times \ln(\text{Odds}) + \text{PDO} = \text{Offset} + \text{Factor} \times \ln(2) + \text{Factor} \times \ln(\text{Odds})$$

eliminando los términos comunes:

$$\text{PDO} = \text{Factor} \times \ln(2) \iff \text{Factor} = \frac{\text{PDO}}{\ln(2)}$$

Asimismo, considerando una puntuación base y unas *odds* base previamente definidas, se obtiene:

$$\text{Offset} = \text{Score}_{\text{base}} - \text{Factor} \times \ln(\text{Odds}_{\text{base}})$$

Estas expresiones permiten convertir directamente la salida de la regresión logística en un sistema de puntuación aditivo e interpretable, donde cada variable aporta una cantidad específica de puntos y la suma de dichas contribuciones determina el nivel de riesgo crediticio asociado a cada individuo.

Para la implementación en Python se consideraron como base $\text{pdo} = 20$, $\text{Score}_{\text{base}} = 600$ y $\text{Odds}_{\text{base}} = 50$

```
1 pdo = 20
2 Score_base = 600
3 Odds_base = 50
4 factor = pdo / np.log(2); offset = Score_base - factor * np.log(Odds_base)
5 intercepto = logit.intercept_[0]
```

```

6 k = len(woe_features)
7
8 filas = []
9 for var, beta in zip(vars_sel, logit.coef_[0]):
10     for _, r in _bins_reales(bins_orig[var]).iterrows():
11         puntos = -(beta * r['WoE'] + intercepto / k) * factor + offset / k
12         filas.append({'Variable': var, 'Tramo': r['Bin'], 'WoE': round(r['WoE'],4),
13                        'Puntos': round(puntos)})
14 scorecard = pd.DataFrame(filas)
15 print('Scorecard :'); scorecard.head(50)

```

Para ello, se recorre cada variable y cada uno de sus tramos asociados, utilizando el valor WoE y el coeficiente estimado por la regresión logística para calcular la contribución individual en puntos. Adicionalmente, el intercepto del modelo se distribuye proporcionalmente entre el número total de variables consideradas, permitiendo expresar el riesgo como una estructura aditiva donde el puntaje final corresponde a la suma de las contribuciones de cada característica del individuo.

Cuadro 4.16: Estructura del *ScoreCard* | Balance por *Oversampling*




Variable	WoE	Pts	Variable	WoE	Pts	Variable	WoE	Pts
Ingreso ≤ 18,514.5	0.4339	76	Saldo ≤ 14,738.5	0.3692	75	Línea ≤ 56,891	0.8120	80
18,514.5 ≤ Ingreso < 24,630	0.1309	72	14,738.5 ≤ Saldo < 172,991	0.0851	71	56,891 ≤ Línea < 154,483	0.1496	72
24,630 ≤ Ingreso < 40,336.5	0.1224	71	172,991 ≤ Saldo < 211,838.5	0.0115	70	154,483 ≤ Línea < 244,328.5	0.0986	71
40,336.5 ≤ Ingreso < 63,116.5	-0.0321	69	Saldo ≥ 211,838.5	-0.5511	62	244,328.5 ≤ Línea < 583,503	-0.2859	66
63,116.5 ≤ Ingreso < 73,418.5	-0.1012	68	Soltero	1.6977	121	Línea ≥ 583,503	-0.4663	63
73,418.5 ≤ Ingreso < 100,191	-0.4530	63	Viudo	-0.1019	66	Uso ≤ 10.75	0.6682	84
Ingreso ≥ 100,191	-0.6093	60	Casado	-0.2869	61	10.75 ≤ Uso < 16.21	0.3839	78
Score ≤ 567.5	1.1986	103	Divorciado	-0.3434	59	16.21 ≤ Uso < 67.72	-0.0595	68
567.5 ≤ Score < 595.5	0.0188	70				Uso ≥ 67.72	-0.0641	68
595.5 ≤ Score < 640.5	0.0096	70				Edad ≤ 24.5	1.3013	105
Score ≥ 640.5	-0.0798	67				24.5 ≤ Edad < 28.5	0.3942	80
						28.5 ≤ Edad < 31.5	0.0305	70
						31.5 ≤ Edad < 35.5	-0.0860	67
						Edad ≥ 35.5	-0.1243	66

Cuadro 4.17: Estructura del *ScoreCard* | Balance por percentiles

Variable	WoE	Pts	Variable	WoE	Pts	Variable	WoE	Pts
Ingreso ≤ 24,819	0.6931	79	Saldo ≤ 14,218	0.6931	64	Línea ≤ 52,850.5	1.0986	89
24,819 ≤ Ingreso < 76,615.5	-0.0274	69	14,218 ≤ Saldo < 67,479.5	0.3228	67	52,850.5 ≤ Línea < 215,604.5	0.3037	75
76,615.5 ≤ Ingreso < 102,013	-0.6931	61	67,479.5 ≤ Saldo < 135,499.5	-0.1252	71	215,604.5 ≤ Línea < 548,135	-0.6539	58
Ingreso ≥ 102,013	-1.9459	44	135,499.5 ≤ Saldo < 203,305.5	-0.5596	74	Línea ≥ 548,135	-0.9163	54
Score ≤ 564	0.2877	76	Saldo ≥ 203,305.5	-0.6931	75	Uso ≤ 13.83	0.7885	88
564 ≤ Score < 729.5	0.1431	73	Soltero	0.7885	88	13.83 ≤ Uso < 67.74	0.0000	70
729.5 ≤ Score < 783.5	-0.1054	67	Casado	-0.1178	67	67.74 ≤ Uso < 86.35	-0.0800	68
Score ≥ 783.5	-0.7885	52	Divorciado	-0.2719	63	Uso ≥ 86.35	-1.7918	28
			Viudo	-0.4418	59	Edad ≤ 35.5	0.1719	72
						Edad 35.5 ≤ Edad < 45.5	0.1603	72
						Edad ≥ 45.5	-0.3448	65

Cuadro 4.18: Estructura del *ScoreCard* | Balance por *Class Weight*

Variable	WoE	Pts	Variable	WoE	Pts	Variable	WoE	Pts
Ingreso ≤ 24,914.5	0.4334	81	Saldo ≤ 67841.5	0.1845	77	Línea ≤ 61,691	0.5668	58
24,914.5 ≤ Ingreso < 41,700.5	0.1199	73	67,841.5 ≤ Saldo < 215,265.5	0.0692	72	61,691 ≤ Línea < 223,547.5	0.1593	66
41,700.5 ≤ Ingreso < 76,016	0.0317	70	Saldo ≥ 215,265.5	-0.6631	43	223,547.5 ≤ Línea < 252,395.5	-0.0086	70
Ingreso ≥ 76,016	-0.8042	48	Soltero	0.4836	87	252,395.5 ≤ Línea < 487,582	-0.2905	76
Score ≤ 561.5	0.7664	88	Viudo	0.1111	74	Línea ≥ 487,582	-0.4739	80
561.5 ≤ Score < 638.5	0.1395	73	Casado	-0.1628	64	Uso ≤ 39.67	-0.2520	57
638.5 ≤ Score < 762.5	0.0426	71	Divorciado	-0.2820	59	39.67 ≤ Uso < 43.84	0.0548	72
762.5 ≤ Score < 785.5	-0.0977	67				Uso ≥ 43.84	0.2359	81
Score ≥ 785.5	-0.6599	54				Edad ≤ 51.5	-0.0691	67
						Edad ≥ 51.5	0.4279	85

(a) Distribución de puntajes, $cutoff = 474$ (b) Distribución de puntajes, $cutoff = 472$ (c) Distribución de puntajes, $cutoff = 476$

Los resultados del ScoreCard muestran que variables relacionadas con el comportamiento crediticio y capacidad financiera presentan una contribución importante sobre el riesgo estimado. En términos generales, mayores niveles de score de buró y menores porcentajes de utilización de crédito generan una mayor asignación de puntos, asociándose con perfiles de menor probabilidad de incumplimiento.

4.3. Comparación de modelos, e interpretaciones

Cuadro 4.19: Resultados del modelo de regresión logística con balance por *Oversampling*

Etap	Métrica	Clase 0	Clase 1	Valor
Validación cruzada	AUC por fold	–	–	[0.7149, 0.7029, 0.7031, 0.7112, 0.7129]
	AUC promedio	–	–	
TEST	Precision	0.994	0.006	–
	Recall	0.499	0.500	–
	F1-score	0.664	0.011	–
	Support	3480	20	–
	Accuracy	–	–	0.499
OOT	Precision	0.993	0.005	–
	Recall	0.505	0.429	–
	F1-score	0.669	0.010	–
	Support	3479	21	–
	Accuracy	–	–	0.504
Desempeño global	AUC TEST	–	–	0.4999
	AUC OOT	–	–	0.4438




Figura 4.5: Matriz de confusión del modelo de origenación con balance por *Oversampling*




Figura 4.6: Curva ROC del modelo de originación con balance por *Oversampling*

Cuadro 4.20: Resultados del modelo de regresión logística con balance por *Percentiles*

Etapa	Métrica	Clase 0	Clase 1	Valor
Validación cruzada	AUC por fold	–	–	[0.7101, 0.6282, 0.5897, 0.8013, 0.6410]
	AUC promedio	–	–	
TEST	Precision	0.994	0.005	–
	Recall	0.515	0.450	–
	F1-score	0.678	0.010	–
	Support	3480	20	–
	Accuracy	–	–	0.515
OOT	Precision	0.992	0.004	–
	Recall	0.521	0.333	–
	F1-score	0.683	0.008	–
	Support	3479	21	–
	Accuracy	–	–	0.519
Desempeño global	AUC TEST	–	–	0.4754
	AUC OOT	–	–	0.4631




Figura 4.7: Matriz de confusión del modelo de originación con balance por *percentiles*




Figura 4.8: Curva ROC del modelo de origenación con balance por *percentiles*

Cuadro 4.21: Resultados del modelo de regresión logística con balance por *Class Weight*

Etapa	Métrica	Clase 0	Clase 1	Valor
Validación cruzada	AUC por fold	–	–	[0.6447, 0.5811, 0.7485, 0.5268, 0.7171]
	AUC promedio	–	–	0.6436
TEST	Precision	0.994	0.006	–
	Recall	0.647	0.350	–
	F1-score	0.784	0.011	–
	Support	3480	20	–
	Accuracy	–	–	0.645
OOT	Precision	0.996	0.009	–
	Recall	0.642	0.524	–
	F1-score	0.780	0.017	–
	Support	3479	21	–
	Accuracy	–	–	0.641
Desempeño global	AUC TEST	–	–	0.4437
	AUC OOT	–	–	0.5659




Figura 4.9: Matriz de confusión del modelo de origenación con balance por *Class Weight*




Figura 4.10: Curva ROC del modelo de originación con balance por *Class Weight*

Claramente, dado el tipo de tratamiento al balance de los datos, este tendría un impacto en el entrenamiento del modelo logístico, construcción del ScoreCard y finalmente en las pruebas posteriores que evalúan el rendimiento de los modelos.

Con base en las métricas obtenidas para los tres enfoques de balanceo, la selección del modelo final se fundamenta en indicadores que reflejan tanto la capacidad predictiva como el impacto sobre la rentabilidad del negocio.

Entre las métricas más relevantes se encuentran el área bajo la curva ROC fuera de muestra (AUC OOT), el *Recall* de la clase de mora, la exactitud (*Accuracy*) y la estabilidad entre las muestras de prueba y validación temporal. El método de *Oversampling* presenta el mayor *Recall* en la muestra TEST (0.500), lo que indica una mejor capacidad inicial para detectar clientes morosos; sin embargo, su desempeño global resulta prácticamente equivalente a una clasificación aleatoria, reflejado en un AUC OOT de 0.4438, además de presentar una precisión extremadamente baja para la clase de mora, generando una elevada cantidad de falsos positivos y potenciales pérdidas por rechazo de clientes con buen perfil crediticio.

Por su parte, el método basado en *Percentiles* muestra una ligera mejora en la exactitud general, aunque continúa presentando una capacidad discriminatoria insuficiente fuera de muestra (AUC OOT de 0.4631).

En contraste, el método de *Class Weight* exhibe el mejor desempeño fuera de muestra (AUC OOT de 0.5659), mantiene la mayor exactitud general y presenta un equilibrio más adecuado entre detección de clientes riesgosos y estabilidad del modelo. Aunque su *Recall* en TEST es menor, logra el mejor comportamiento en OOT y reduce el riesgo de decisiones excesivamente conservadoras o agresivas. Desde una perspectiva de originación y rentabilidad financiera, donde el objetivo consiste en maximizar la colocación de crédito minimizando simultáneamente el riesgo de incumplimiento, el modelo con balanceo mediante *Class Weight* puede considerarse como la alternativa más robusta y equilibrada para su implementación.

Cuadro 4.22: Comparación de métricas relevantes entre métodos de balanceo

Métrica	Oversampling	Percentiles	Class Weight
AUC promedio validación cruzada	0.7090	0.6741	0.6436
Accuracy TEST	0.499	0.515	0.645
Accuracy OOT	0.504	0.519	0.641
Recall mora TEST	0.500	0.450	0.350
Recall mora OOT	0.429	0.333	0.524
Precisión mora OOT	0.005	0.004	0.009
AUC TEST	0.4999	0.4754	0.4437
AUC OOT	0.4438	0.4631	0.5659
Estabilidad TEST-OOT	Baja	Media	Alta
Balance negocio-riesgo	Bajo	Medio	Alto

Como criterio final de selección, el modelo con balanceo mediante *Class Weight* se considera el modelo óptimo para la etapa de originación, debido a que proporciona el mejor compromiso entre estabilidad, capacidad de discriminación y desempeño fuera de muestra. Si bien no maximiza la detección de eventos de mora en la muestra de prueba, presenta el comportamiento más consistente y una mejor generalización temporal, lo que permite reducir pérdidas asociadas tanto a la aprobación de clientes con alto riesgo de incumplimiento como al rechazo innecesario de clientes potencialmente rentables. En consecuencia, este enfoque favorece una cartera con un perfil más equilibrado entre crecimiento y control del riesgo crediticio.

4.4. Modelo final para la originación

Es importante señalar que, aunque los valores obtenidos del AUC-ROC del modelo final presentan niveles relativamente bajos, este resultado no implica necesariamente una inadecuada utilidad del modelo dentro del proceso de originación crediticia. La métrica AUC evalúa la capacidad global de discriminación probabilística del modelo a través de todos los posibles puntos de corte; sin embargo, en un contexto real de negocio la decisión de otorgamiento no se fundamenta sobre la totalidad de dichos umbrales, sino sobre un punto de corte específico definido por criterios financieros y de apetito de riesgo.

En otras palabras, la regresión logística genera probabilidades de incumplimiento asociadas a cada cliente, pero la decisión final de aprobar o rechazar una solicitud de crédito no depende directamente de dichas probabilidades, sino de una regla determinística establecida mediante un *cut-off* o punto de decisión. Bajo este enfoque, un problema originalmente probabilístico y de naturaleza estadística se transforma en una decisión operacional concreta. Consecuentemente, un modelo puede presentar valores moderados o bajos de AUC y aun así ser funcional si el punto de corte seleccionado logra un equilibrio adecuado entre rentabilidad y riesgo crediticio.

Adicionalmente, la naturaleza de la base de datos utilizada representa un factor relevante en el desempeño observado. La muestra presenta un fuerte desbalance entre eventos de mora y no mora, lo que limita la capacidad discriminatoria global del modelo y dificulta la separación entre ambas clases. Desde una perspectiva de negocio resulta más relevante evaluar el desempeño del modelo alrededor del umbral operativo seleccionado, priorizando el impacto económico derivado de la aprobación o rechazo de clientes.

A partir del *scorecard* construido en la sección 4.2.4 se definió un punto de corte con el propósito de transformar las probabilidades estimadas por el modelo en decisiones operativas de negocio. Bajo este enfoque se estableció una política de aceptación basada en tres categorías: aprobación

automática, revisión manual y rechazo. Los resultados muestran que aproximadamente el 70.09 % de la población puede ser aprobada con una probabilidad promedio de incumplimiento relativamente menor, mientras que el 20 % correspondiente a los clientes con mayor riesgo se clasifica dentro del segmento de rechazo. Adicionalmente, un 9.91 % de las solicitudes se asigna a revisión manual, permitiendo incorporar criterios adicionales de evaluación antes de emitir una decisión definitiva.




Figura 4.11: Modelo de originación: punto de corte, política de aceptación y segmentación del riesgo

De forma complementaria, se realizó una segmentación por grados de riesgo mediante quintiles del puntaje obtenido, clasificando a los clientes desde el nivel A (menor riesgo) hasta el nivel E (mayor riesgo). Se observa un comportamiento consistente entre el score y el riesgo estimado, ya que conforme disminuye el puntaje incrementa la probabilidad promedio de incumplimiento y la tasa de mora esperada. Esta segmentación permite establecer tratamientos diferenciados para cada perfil de cliente y convierte al modelo en una herramienta de originación aplicable a la administración y control de la cartera crediticia.

Cuadro 4.23: Política de aceptación y segmentación del riesgo

Grado	Créditos	Score mínimo	Score máximo	PD promedio (%)	Tasa mora (%)	Tratamiento
E (mayor riesgo)	3500	408	476	67.64	1.11	Rechazo o garantía adicional
D	3500	476	490	53.14	0.66	Línea baja, precio alto, revisión manual
C	3500	490	500	43.05	0.43	Línea moderada, precio con recargo
B	3500	500	513	34.69	0.43	Línea estándar, aprobación automática
A (menor riesgo)	3500	513	565	22.58	0.34	Línea amplia, precio preferente

Modelo de cobranza

A diferencia de la originación, donde la variable objetivo es un evento observable (el incumplimiento a 90 días bajo Basilea II), el modelo de cobranza opera sobre clientes que ya pertenecen a la cartera y para quienes interesa graduar el deterioro más que registrar la mora consumada. En el modelo se construye un semáforo de riesgo ordinal de tres niveles sobre el cual se entrena un *Random Forest* multiclase, elegido por capturar interacciones no lineales entre variables de pago conservando interpretabilidad. La teoría previa de este modelo de aprendizaje supervisado se basa en [1].

5.1. Construcción de la variable objetivo

El semáforo de cobranza se construyó mediante un score híbrido que combina distintas dimensiones del deterioro financiero del cliente. La idea detrás de este enfoque es que una sola variable no logra describir completamente el riesgo de cobranza. Por ejemplo, los días de atraso reflejan la severidad inmediata de la mora, pero no muestran si el incumplimiento es recurrente, si existe presión financiera persistente o si hay factores adicionales relacionados con garantías. Por esta razón, el score integra información de comportamiento, capacidad de pago y respaldo crediticio dentro de una sola medida ordinal.

$$Score_{Cobranza} = 0.45 Score_{Dias} + 0.35 Score_{Atrasos} + 0.15 Score_{Minimo} + 0.05 Proxy_{Garantia}.$$

Cada componente transforma una variable continua en un puntaje discreto entre 0 y 2, mientras que el componente asociado a garantías se maneja de forma binaria. Los criterios utilizados se muestran en el Cuadro 5.1.

Cuadro 5.1: Esquema de puntuación ordinal por dimensión de deterioro y ponderación.

Dimensión (variable base)	Tramos	Puntaje	Peso
$Score_{Dias}$ (dias_atraso)	≤ 15 / (15, 60] / > 60	0/1/2	0.45
$Score_{Atrasos}$ (porcentaje_atrasos)	≤ 10 / (10, 35] / > 35	0/1/2	0.35
$Score_{Minimo}$ (porcentaje_pago_minimo)	≤ 30 / (30, 70] / > 70	0/1/2	0.15
$Proxy_{Garantia}$ (FLAG_GARANTÍAS)	$= 0$ / $= 1$	0/1	0.05

La asignación de pesos sigue una lógica alineada con el proceso de recuperación. La severidad de la mora recibe el mayor peso (0.45) porque representa la señal más directa de deterioro. Después aparece la frecuencia de atrasos (0.35), que permite identificar si el incumplimiento es persistente en el tiempo. El porcentaje de pago mínimo (0.15) funciona como una señal temprana de estrés financiero, ya que pagar únicamente el mínimo suele reflejar problemas de liquidez aun cuando todavía no exista una mora severa. Por último, la variable de garantías participa con un peso menor (0.05), debido a que actúa más como un elemento mitigante del riesgo que como una señal directa de incumplimiento.

El score total queda acotado en el intervalo $[0, 1.95]$. Esto ocurre porque los componentes ordinales toman valores entre 0 y 2, mientras que la variable de garantía únicamente puede tomar valores de 0 o 1. En consecuencia, el valor máximo posible se obtiene cuando todas las dimensiones presentan el nivel más alto de deterioro,

$$0.45(2) + 0.35(2) + 0.15(2) + 0.05(1) = 1.95.$$

De esta forma se obtiene una escala compacta y fácil de interpretar para segmentar el riesgo de cobranza.

$$Nivel_{Riesgo} = \begin{cases} 0 \text{ (Verde)}, & Score \leq 0.60, \\ 1 \text{ (Amarillo)}, & 0.60 < Score \leq 1.30, \\ 2 \text{ (Rojo)}, & Score > 1.30. \end{cases}$$

La construcción de los puntos de corte sigue directamente la lógica del score ponderado. Debido a que la componente con mayor peso es $Score_{Dias}$ (0.45), un cliente puede presentar una señal leve de atraso y aun así mantenerse dentro de Verde, siempre que el resto de dimensiones no muestre deterioro relevante. Por ejemplo, un cliente con $Score_{Dias} = 1$ y valores bajos en las demás variables obtiene un score cercano a 0.45, todavía por debajo del umbral de 0.60.

El límite superior de Amarillo también responde a esta estructura. Para alcanzar Rojo no basta con una única señal aislada de riesgo, sino que normalmente se requiere la combinación de varias dimensiones deterioradas. Por ejemplo, un cliente con mora severa ($Score_{Dias} = 2$) aporta por sí solo 0.90 al score total, pero necesita además atrasos recurrentes, estrés financiero o presencia de garantía para superar el umbral de 1.30. Esto evita clasificar como alto riesgo a clientes con eventos puntuales y concentra la categoría Roja en perfiles con deterioro más consistente.

En consecuencia, el nivel Amarillo funciona como una zona intermedia de transición. Aquí se ubican clientes que todavía no presentan un deterioro extremo, pero sí señales suficientes para justificar seguimiento preventivo y estrategias tempranas de cobranza.

El Cuadro 5.2 resume la definición final de la variable objetivo y la distribución observada en la cartera.

Cuadro 5.2: Definición de la variable objetivo y distribución de la cartera.

Valor	Semáforo	Nivel	Regla sobre $Score_{Cobranza}$	Frec.	%
0	Verde	Bajo	$Score \leq 0.60$	5,710	32.63
1	Amarillo	Medio	$0.60 < Score \leq 1.30$	9,875	56.43
2	Rojo	Alto	$Score > 1.30$	1,915	10.94
Total				17,500	100.00

5.2. Configuración y preparación de los datos

Primero se definen los diccionarios asociados al semáforo de riesgo y posteriormente se separan las variables utilizadas para construir la etiqueta de aquellas que se emplearán como predictores dentro del modelo.

```

1 [language=Python]
2 COD_RIESGO = {'Verde': 0, 'Amarillo': 1, 'Rojo': 2}
3 NOM_RIESGO = {0: 'Verde', 1: 'Amarillo', 2: 'Rojo'}
4 vars_cob = ['porcentaje_pago_minimo', 'porcentaje_pago_total', 'porcentaje_atrasos',
5             'porcentaje_saldo_financiado', 'porcentaje_credito_utilizado',
6             'porcentaje_uso', 'saldo_Insoluto', 'FLAG_GARANTIAS']
7 vars_target = ['dias_atraso', 'porcentaje_atrasos', 'porcentaje_pago_minimo',
8                'FLAG_GARANTIAS']
9
10 for c in vars_cob + vars_target:
11     df[c] = pd.to_numeric(df[c], errors='coerce')
12 df = df.dropna(subset=list(set(vars_cob + vars_target))).reset_index(drop=True)

```

```

12
13 Xc_tr, Xc_tmp, yc_tr, yc_tmp = train_test_split(df[vars_cob], df['nivel_riesgo'],
14         train_size=.60, stratify=df['nivel_riesgo'], random_state=semilla)
15 Xc_te, Xc_oo, yc_te, yc_oo = train_test_split(Xc_tmp, yc_tmp,
16         test_size=.50, stratify=yc_tmp, random_state=semilla)

```

La transformación con `errors='coerce'` permite identificar registros con valores no válidos y, posteriormente, el `dropna` elimina cualquier observación con información faltante en las variables relevantes para el modelo. De esta manera se garantiza trabajar únicamente con registros completos y consistentes.

La división de los datos se realizó bajo un esquema estratificado 60/20/20 utilizando la variable `nivel_riesgo`. Esto es especialmente importante debido al desbalance entre clases mostrado en el Cuadro 5.2, ya que una partición aleatoria convencional podría dejar muy pocos casos de nivel Rojo en alguno de los conjuntos y afectar la evaluación del modelo. Con la estratificación se mantienen proporciones similares en entrenamiento, prueba y OOT, con aproximadamente 10,500, 3,500 y 3,500 observaciones respectivamente.

Un aspecto importante es que algunas variables aparecen tanto en `vars_target` como en `vars_cob`, particularmente `porcentaje_atrasos`, `porcentaje_pago_minimo` y `FLAG_GARANTÍAS`. Esta coincidencia es intencional, ya que la meta del modelo no es descubrir una relación completamente nueva, sino transformar una política de negocio previamente definida en una estimación probabilística más flexible. Sin embargo, la variable con mayor peso dentro de la construcción de la etiqueta, `dias_atraso`, fue excluida deliberadamente de los predictores.

5.3. Balanceo de clases

El balanceo se decide comparando el cociente entre la clase minoritaria y la mayoritaria del *train* contra un umbral de 0.55. La distribución original (Verde 3,426, Amarillo 5,925, Rojo 1,149) da un cociente $1,149/5,925 \approx 0.19$, muy por debajo del umbral, por lo que se aplica un submuestreo aleatorio con estrategia `'not minority'` que iguala las clases mayoritarias a la minoritaria, dejando 1,149 casos por clase. Se prefirió el submuestreo al sobremuestreo sintético (SMOTE) por la naturaleza ordinal: interpolar entre vecinos podría generar registros cuyo puntaje implícito no respete los umbrales del semáforo y contaminar la frontera entre niveles. Como segunda capa, el bosque usa `class_weight='balanced_subsample'`, que reequilibra dentro de cada árbol.

5.4. Entrenamiento del Random Forest multiclase y validación cruzada

```

1 rf = RandomForestClassifier(
2     n_estimators=350, max_depth=8, min_samples_leaf=25, min_samples_split=40,
3     max_features='sqrt', class_weight='balanced_subsample',
4     random_state=semilla, n_jobs=-1).fit(Xc_bal, yc_bal)
5 cv_rf = StratifiedKFold(n_splits=5, shuffle=True, random_state=semilla)
6 auc_cv_rf = cross_val_score(rf, Xc_bal, yc_bal, scoring='roc_auc_ovr_weighted',
        cv=cv_rf)

```

La configuración del modelo se eligió buscando un balance entre capacidad predictiva y control del sobreajuste. Para ello se limitó la profundidad máxima a 8, se exigió un mínimo de 25 observaciones por hoja y 40 por división, además de utilizar únicamente $\sqrt{p}$ variables en cada corte. Esta combinación ayuda a reducir la dependencia entre los 350 árboles y hace que el bosque sea más estable.

La validación cruzada estratificada de cinco pliegues produjo valores de ROC-AUC OVR ponderado de [0.858, 0.831, 0.851, 0.826, 0.843], con un promedio de **0.842** y poca variación entre particiones, lo que muestra un desempeño consistente. De forma complementaria, el *Out-of-Bag*

score de 0.705 se mantiene alineado con la exactitud observada fuera de muestra, dando evidencia de que el modelo conserva una buena capacidad de generalización y no presenta señales importantes de sobreajuste.

5.5. Evaluación del modelo (Test / OOT)

La predicción final se obtiene a partir del valor esperado de las probabilidades estimadas para cada nivel de riesgo, $\hat{y} = \text{round}(\sum_c c P(c))$, restringido al conjunto $\{0, 1, 2\}$. Este enfoque aprovecha la naturaleza ordinal de la escala y hace que los errores entre niveles cercanos tengan menor impacto que las confusiones extremas entre categorías opuestas. Las métricas obtenidas se resumen en el Cuadro 5.3.

Cuadro 5.3: Métricas de desempeño del modelo de cobranza en Test y OOT.

Métrica	Test	OOT	Métrica	Test	OOT
Accuracy	0.654	0.663	MAE ordinal	0.346	0.337
Balanced acc.	0.642	0.647	MSE ordinal	0.346	0.337
AUC OVR (macro)	0.831	0.833	QWK (κ cuad.)	0.565	0.573
AUC OVR (ponder.)	0.807	0.810			

El desempeño se mantiene bastante estable entre Test y OOT, incluso con una ligera mejora en el conjunto fuera de tiempo, lo que da señales de buena capacidad de generalización. Además, un AUC OVR cercano a 0.83 refleja que el modelo logra distinguir adecuadamente entre los distintos niveles de riesgo. Desde la perspectiva ordinal, un MAE de alrededor de 0.34 indica que las predicciones suelen desviarse menos de medio nivel respecto a la categoría real, concentrando la mayoría de los errores entre clases vecinas. El hecho de que el MAE y el MSE prácticamente coincidan sugiere que son muy poco frecuentes las confusiones entre niveles extremos. Por otra parte, el valor de QWK cercano a 0.57 muestra una concordancia moderada con tendencia a ser sólida para este tipo de problemas.

Analizando cada clase de manera individual en OOT, el nivel Amarillo presenta el mejor equilibrio general con un F1 de 0.709. En el caso de Rojo, el *recall* (0.663) es superior a la precisión (0.504), lo que indica que el modelo prefiere identificar más clientes potencialmente riesgosos aunque esto implique algunas falsas alarmas. En un contexto de cobranza este comportamiento suele ser conveniente, ya que el costo de no detectar deterioro es normalmente mayor que el de sobreestimar el riesgo. La menor recuperación observada en Verde (0.547) aparece como la contraparte natural de esta decisión. La Figura 5.2 presenta las matrices de confusión correspondientes.

5.6. Importancia de variables

La relevancia combina la impureza de Gini con la permutación sobre OOT (caída del MAE) en un indicador $0.6 \text{ Gini} + 0.4 \text{ Permutación normalizado}$ (Cuadro 5.4).

Cuadro 5.4: Importancia de variables del Random Forest (impureza, permutación y score combinado).

Variable	Impureza (Gini)	Permutación (–MAE)	Combinado
porcentaje_atrasos	0.5821	0.2985	1.0000
porcentaje_pago_minimo	0.2641	0.1688	0.4984
FLAG_GARANTÍAS	0.0285	0.0156	0.0502
Resto (5 variables) [†]	0.024–0.027	≤ 0.0013	≤ 0.0292

[†] saldo_Insoluto, porcentaje_pago_total, porcentaje_uso, porcentaje_credito_utilizado, porcentaje_saldo_financiado.

El resultado va acorde con lo que se esperaba del modelo. Las variables `porcentaje_atrasos` (1.000) y `porcentaje_pago_minimo` (0.498) terminan siendo las más relevantes porque describen de forma directa cómo se comporta el cliente al momento de pagar. Al no contar con `dias_atraso`, el modelo se apoya en variables que capturan la recurrencia de los incumplimientos, mientras que las demás solo ayudan a complementar la información. En conjunto, esto muestra que el riesgo de cobranza está mucho más relacionado con los hábitos de pago observados que con el nivel de exposición del cliente. Además, la importancia obtenida para cada variable mantiene una relación coherente con la lógica teórica planteada para el modelo.




Figura 5.1: Matrices de confusión multiclase del modelo de cobranza (Test y OOT).

Curvas ROC one-vs-rest (Test)




Figura 5.2: Curva ROC one-vs-rest (Test)

5.7. Semáforo de riesgo y política de cobranza

Para cada cliente se estiman las probabilidades asociadas a los tres niveles de riesgo y, a partir de ellas, se construye un *score* continuo ($\sum_c c P(c)$) que posteriormente se reescala al intervalo $[0, 100]$. El valor final permite asignar de manera directa el semáforo correspondiente. En el Cuadro 5.5 se muestra cómo esta segmentación se traduce en estrategias de cobranza diferenciadas según el nivel de riesgo identificado.

Cuadro 5.5: Política de cobranza y segmentación de la cartera por semáforo (salida del modelo).

Semáforo	Nivel	Clientes	%	Score ₀₋₁₀₀	P(Rojo)	Tratamiento
Verde	Bajo	4,392	25.10	19.4	0.070	Monitoreo estándar
Amarillo	Medio	10,471	59.83	46.0	0.243	Gestión preventiva
Rojo	Alto	2,637	15.07	84.2	0.720	Recuperación intensiva

Los resultados muestran una relación clara entre el semáforo, el *score* y la probabilidad de pertenecer al nivel Rojo, ya que esta aumenta de forma consistente desde 0.070 hasta 0.720. Esto indica que la segmentación logra diferenciar adecuadamente los distintos niveles de riesgo dentro de la cartera. Además, el *score* promedio obtenido fue de 45.08. Comparando la distribución original de la etiqueta con la generada por el modelo, se observa una ligera concentración hacia los niveles de mayor riesgo, lo que refleja una postura más conservadora y orientada a detectar con mayor sensibilidad posibles señales de deterioro.




Figura 5.3: Resumen operativo del modelo de cobranza.

Para ver una visualización del algoritmo sobre la cartera, se puede ver en el siguiente cuadro un extracto del Excel de salida del modelo que clasifica al cliente según su nivel de riesgo:

Cuadro 5.6: Resumen simplificado de la salida en Excel del modelo de cobranza.

ID Cliente	Score ₀₋₁₀₀	P(Verde)	P(Amarillo)	P(Rojo)	P _{max}	Semáforo	Tratamiento
2	16.9	0.718	0.226	0.056	0.718	Verde	Monitoreo estándar
4	55.8	0.175	0.535	0.291	0.535	Amarillo	Gestión preventiva
8	83.5	0.049	0.231	0.720	0.720	Rojo	Recuperación intensiva

En esta tabla, para cada cliente se incluyen las probabilidades asociadas a cada nivel de riesgo, la probabilidad máxima estimada por el modelo, el *score* reescalado entre 0 y 100, el semáforo asignado y la estrategia de tratamiento sugerida. Esto permite interpretar de forma rápida tanto el nivel de riesgo como el grado de confianza asociado a cada clasificación.

Conclusiones

Integrando el cálculo normativo de reservas de la CNBV, el modelo logístico de originación y el sistema predictivo multiclase para cobranza, se conformó un ecosistema robusto y cuantitativo para la gestión del riesgo de crédito. A continuación, se exponen las conclusiones fundamentales de cada módulo y su articulación en el ciclo de vida del activo crediticio.

El análisis del bloque normativo evidenció que el esquema de provisionamiento mediante pérdida esperada ($PE_i = PI_i \times SP_i \times EAD_i$) constituye la frontera mínima de solvencia exigida por la regulación bancaria. No obstante, al basarse en parámetros fijos y agregados, su naturaleza es inherentemente estática y reactiva. Esta limitación paramétrica justificó el desarrollo de los modelos internos subsecuentes, los cuales logran transicionar desde el mero cumplimiento regulatorio hacia la optimización estadística y proactiva de la cartera.

En este sentido, el *scorecard* de originación mitigó eficazmente el fenómeno de selección adversa en la etapa de admisión. La transformación de variables mediante *Weight of Evidence* (WoE) y su filtrado por *Information Value* (IV) garantizaron un ordenamiento del riesgo altamente discriminante que supera las limitaciones de los análisis tradicionales. Asimismo, corregir el severo desbalanceo de clases mediante la penalización de la función de pérdida (*class_weight*) resultó crítico; sin este ajuste actuarial, la asimetría muestral habría anulado la sensibilidad del modelo para detectar perfiles de alto riesgo al nacimiento del crédito.

Por otra parte, el monitoreo continuo del activo fue resuelto mediante el modelo predictivo de cobranza. La migración hacia un algoritmo no paramétrico como *Random Forest* multiclase permitió capturar con éxito las complejas interacciones no lineales y la velocidad de degradación de los acreditados. Un hallazgo técnico fundamental en esta etapa fue la necesidad de aislar la conducta del deudor de las políticas de mitigación: modelar el comportamiento transaccional puro y aplicar las garantías como una capa de decisión posterior (*overlay*) evitó distorsionar el error medio absoluto (MAE), preservando la consistencia ordinal de los semáforos operativos.

Finalmente, este compendio demuestra que las reservas, la originación y la cobranza no operan como silos analíticos aislados, sino como un sistema de ciclo cerrado (*Closed-Loop Risk Management*). La originación actúa como la primera barrera cuantitativa que controla la Probabilidad de Incumplimiento (PI) inicial. Posteriormente, el modelo de cobranza interviene ante alertas tempranas de pago y saldos, conteniendo el deterioro antes de rebasar los umbrales normativos de morosidad severa. Esta contención operativa interrumpe la transición hacia la cartera vencida, impactando retrospectivamente en el cálculo de reservas al disminuir tanto la Exposición (EAD) como la Severidad de la Pérdida (SP). De este modo, la sinergia entre el estándar regulatorio y el aprendizaje automático optimiza la liberación de capital preventivo, maximiza la rentabilidad ajustada por riesgo (RAROC) y transforma la administración de riesgos en una ventaja estratégica institucional.

Bibliografía

- [1] Rojas, G. (2026). *Quiz 6: Administración Integral de Riesgo*. GitHub [Documento PDF]. Disponible en: <https://github.com/Gustavo-Aircraft/AdministracionDeRiesgoPrim2026/blob/7ac112d3fb36e3ef2b3b596ac92d15cdc260da17/Quiz%206.pdf>.
- [2] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.
- [3] BCBS (2006). *International Convergence of Capital Measurement and Capital Standards: A Revised Framework - Comprehensive Version*. Bank for International Settlements.
- [4] Comisión Nacional Bancaria y de Valores (CNBV). (2026). *Disposiciones de Carácter General Aplicables a las Instituciones de Crédito*. Gobierno de México [Documento PDF]. Disponible en: <https://www.cnbv.gob.mx/Normatividad/Disposiciones%20de%20car%C3%A1cter%20general%20aplicables%20a%20las%20instituciones%20de%20cr%C3%A9dito.pdf>.
- [5] Comisión Nacional Bancaria y de Valores (CNBV). (2026). *Anexo 21: Determinación del puntaje crediticio total para créditos a cargo de: personas morales (distintas a entidades federativas, municipios y entidades financieras) y personas físicas con actividad empresarial, con ingresos netos o ventas netas anuales menores al equivalente en moneda nacional a 14 millones de UDIs*. Gobierno de México [Documento PDF]. Disponible en: <https://www.cnbv.gob.mx/Anexos/Anexo%2021%20CUB.pdf>.
- [6] Comisión Nacional Bancaria y de Valores (CNBV). (2026). *Anexo 22: Determinación del puntaje crediticio total para créditos a cargo de personas morales (distintas a entidades federativas, municipios y entidades financieras) y personas físicas con actividad empresarial, con ingresos netos o ventas netas anuales mayores o iguales al equivalente en moneda nacional a 14 millones de UDIs*. Gobierno de México [Documento PDF]. Disponible en: <https://www.cnbv.gob.mx/Anexos/Anexo%2022%20CUB.pdf>.
- [7] scikit-learn Developers. (2026). *LogisticRegression — scikit-learn documentation*. Disponible en: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html.
- [8] scikit-learn Developers. (2026). *RandomForestClassifier — scikit-learn documentation*. Disponible en: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>.